

OBESIDADE

INFLUÊNCIAS COMPORTAMENTAIS E HISTÓRICO FAMILIAR



31 DE MAIO

POS TECH 11DTAT

Criado por: Luci Aguiar

INTRODUÇÃO

Obesidade

Segundo a Organização Mundial da Saúde (OMS), a **obesidade** é uma doença crônica caracterizada pelo acúmulo anormal ou excessivo de gordura no corpo, em quantidade que compromete a saúde. É considerada um dos maiores problemas globais de saúde pública.

Riscos à Saúde

A OMS alerta que o excesso de gordura é um fator de risco determinante para o desenvolvimento de diversas doenças graves, tais como:

- Hipertensão (pressão alta)
- Diabetes tipo 2
- Doenças cardiovasculares
- Problemas articulares e respiratórios
- Certos tipos de câncer

Causas

A obesidade é uma condição complexa e multifatorial, envolvendo predisposição genética, metabolismo e fatores ambientais (como alimentação inadequada e sedentarismo).

Objetivo do Documento

Este documento apresenta análises da influência do comportamento da população em relação a sua condição física, no âmbito do peso atual. Os dados da pesquisa foram obtidos através de um arquivo fornecido pela empresa que solicitou este estudo. Além da análise dos dados aqui apresentada, também foi desenvolvida uma aplicação, utilizando modelo de machine learning, para auxiliar equipes médicas a determinar o possível nível de obesidade de indivíduos, considerando apenas seu estilo de vida.

Sumário

METODOLOGIA DO ESTUDO 4

Arquivos de Dados..... 4

REFINAMENTO E PREPARAÇÃO DOS DADOS..... 5

Dicionário de Dados..... 5

Limpeza e Refinamento dos Dados 5

ANÁLISE EXPLORATÓRIA DE DADOS (EDA)..... 6

Avaliação do Balanceamento do Vetor Alvo 6

Análise Univariada das Features Contínuas 7

Relações Bivariadas: Comportamento vs. Obesidade..... 8

Engenharia de Atributos: O Impacto do IMC Analítico 9

Análise de Correlação 10

Análise de correlação sem o IMC 11

APRENDIZADO DE MÁQUINA - MACHINE LEARNING 14

Aplicativo 15

CONCLUSÃO 16

METODOLOGIA DO ESTUDO

A base de dados utilizada como referência apresenta um recorte da condição física da sociedade em geral. Por não ter acesso aos critérios utilizados na escolha dos indivíduos da pesquisa, não é possível determinar se há representatividade o suficiente para determinar se os hábitos de vida coletados refletem o que já é conhecido cientificamente sobre os fatores que influenciam na condição física da população em geral.

Arquivos de Dados

O arquivo usado como referência na pesquisa apresenta 2111 linhas de dados, onde foram respondidas as seguintes perguntas:

- Gênero;
- Idade;
- Altura;
- Peso atual;
- Histórico familiar de obesidade;
- Frequência de consumo de alimentos altamente calóricos;
- Consumo de vegetais;
- Número de refeições principais diárias;
- Consumo de alimentos entre as refeições principais;
- Fumante;
- Quantidade de água consumida diariamente;
- Costume de monitorar as calorias ingeridas;
- Frequência de atividade física;
- Tempo diário de uso de dispositivos tecnológicos;
- Ingestão de bebidas alcoólicas;
- Meio principal de transporte.

No arquivo há uma coluna determinando o nível de obesidade atual, cujos parâmetros utilizados para sua definição é o objetivo deste estudo.

REFINAMENTO E PREPARAÇÃO DOS DADOS

Dicionário de Dados

Junto da planilha Excel com os dados da pesquisa também foi fornecido um dicionário de dados explicativo de cada coluna, tipagem dos dados e respostas possíveis.

Foi verificado que o arquivo possuía dados não padronizados, sendo necessário fazer um tratamento de limpeza, padronização de tipagem e refinamento dos dados antes de iniciar a análise.

Limpeza e Refinamento dos Dados

Em colunas como Idade, foram encontrados dados tais como 25.196.214, 18.503.343, 21.853.826, 2.190.012... Isso sugere que a base de dados sofreu algum problema na sua extração.

Para isso foram utilizadas técnicas de limpeza de dados, utilizando como referência o dicionário de dados fornecido.

Exemplos:

- Idade: no dicionário de dados foi informado que a faixa etária dos indivíduos da pesquisa é entre 14 e 61 anos. Portanto, consideramos que o número 25.196.214 representa a idade 25 anos, removendo toda a informação após o primeiro ponto.
- Altura: no dicionário de dados foi informado que a altura está em metros e os valores estão entre 1.45 e 1.98 m. Havia dados de altura tais como 1.686.306, 1.683.124, 1.622.397... Para cada caso foi desenvolvida uma lógica com a finalidade de transformar este dado para que ficasse dentro dos limites estabelecidos no dicionário de dados.

ANÁLISE EXPLORATÓRIA DE DADOS (EDA)


O plano de ação para possibilitar a análise de dados começa pela adequação da qualidade dos dados que foram fornecidos para o modelo de machine learning.

Com a base higienizada, também foram feitas conversões de tipagem, preparando os dados para cálculos estatísticos e plotagens sem os ruídos de tipagem do arquivo original.

A pipeline de Análise Exploratória de Dados (EDA) foi focada em extrair *insights* diretos sobre o comportamento das variáveis e preparar o terreno para otimizar aquele modelo de *Random Forest*.


Avaliação do Balanceamento do Vetor Alvo

O gráfico de distribuição das classes de obesidade pela quantidade total nos mostra que a limpeza e tratamento dos dados não alterou a quantidade de linhas do dataset:



Análise Univariada das Features Contínuas

Verificamos se os dados idade, altura e peso fazem sentido através da análise de dispersão, com o objetivo de identificar assimetria ou a presença de *outliers* legítimos.



Distribuição por Idade

Nota-se que existe uma concentração de pessoas na faixa etária entre 20 e 30 anos no Dataset, indicando que a idade não deve ser um fator altamente considerado nas análises dos dados. Uma vez que não há uma distribuição uniforme de pessoas pesquisadas em relação a idade, a análise pode não corresponder a realidade.

Distribuição por Altura


Separamos a altura em 4 categorias, visto que a altura absoluta é muito variada na amostragem. Percebe-se que a maior concentração de pessoas da pesquisa está de acordo com a média de altura da população em geral, entre 1.58m e 1.85m.

Distribuição por Peso

Este gráfico enfatiza o que já estava claro no gráfico de balanceamento do fator alvo, obesidade. O maior volume de pessoas se encontra na faixa dos 70 a 80 kg. Cruzando com os dados de altura, vemos que a maioria dos pesquisados está nos níveis de obesidade Tipo 1 e Obesidade Tipo 2.

Relações Bivariadas: Comportamento vs. Obesidade

Cruzamento das classes clínicas com os hábitos mapeados no dicionário de dados. O objetivo é identificar a variância de peso entre pessoas que consomem alimentos altamente calóricos frequentemente impacta na classificação.



Densidade e Concentração nas Classes Severas

A nuvem de pontos correspondente aos pacientes que responderam "Sim" para o FAVC apresenta uma concentração esmagadora nas faixas superiores do eixo Y (onde se localizam Obesity_Type_I, II e III). O gráfico evidencia visualmente que a ingestão calórica elevada e frequente é praticamente um pré-requisito para os estágios mais avançados de obesidade nesta amostra.

A Dispersão do "Não" e Fatores de Proteção

Na coluna de dispersão dos pacientes que responderam "Não" ao consumo frequente de alta caloria, o agrupamento se inverte. A massa de dados "escorrega" para a base do gráfico, concentrando-se pesadamente em Normal_Weight e Insufficient_Weight.

Zonas de Transição (Sobrepeso)

É interessante notar a área do meio do gráfico (Overweight_Level_I e II). Aqui, a dispersão começa a ficar mista, com pontos distribuídos tanto no "Sim" quanto no "Não". Há pessoas com sobrepeso leve que não consomem alta caloria frequentemente (provavelmente afetadas por outros fatores, como ausência de atividade física ou histórico familiar).

Engenharia de Atributos: O Impacto do IMC Analítico


A OMS classifica os níveis de obesidade através do cálculo do **Índice de Massa Corporal (IMC)**, que divide o peso da pessoa (em kg) pela sua altura (em metros) elevada ao quadrado:

$$IMC = \frac{peso}{altura^2}$$

A classificação padrão adotada é:


- **Abaixo do peso:** menor que 18,5
- **Peso normal:** 18,5 a 24,9
- **Sobrepeso:** 25,0 a 29,9
- **Obesidade Grau I:** 30,0 a 34,9
- **Obesidade Grau II:** 35,0 a 39,9
- **Obesidade Grau III (Mórbida):** 40,0 ou mais [[1](#), [2](#), [3](#)]

Sabendo que os algoritmos de árvore maximizam o ganho de informação a cada nó (*split*), fornecer o Índice de Massa Corporal exato aumentará dramaticamente o poder preditivo para diferenciar os níveis de sobrepeso e obesidade.



Análise de Correlação

Para analisar a correlação entre todas as features do dataset, utilizamos o heatmap.



A Força do IMC e do Peso (Weight):

Vimos que a variável Obesity tem uma correlação fortíssima com o Weight (**0.85**) e com o IMC (**0.84**).

O Weight e o IMC possuem uma correlação quase perfeita entre si (**0.93**).

Para um modelo de machine learning, isso pode implicar no algoritmo desprezar as demais features.

Histórico Familiar (family_history):


Existe uma correlação positiva moderada (**0.30**) entre ter histórico familiar e a classificação de obesidade. Isso prova clinicamente que a genética/ambiente familiar tem um peso estatístico considerável na base.

Comportamentos que não correlacionam linearmente:

Fumar (SMOKE) e o meio de transporte (MTRANS) apresentam correlações lineares quase nulas com o nível de obesidade (próximas de 0.00 a 0.04).

Análise de correlação sem o IMC

Para analisar a correlação dos fatores comportamentais (desconsiderando o peso e altura) com a tendência a obesidade, agrupamos os níveis de obesidade a partir Obesity_Type1, criando a variável IS_Obesity e construímos um novo heatmap.



Histórico Familiar (family_history): +0.42

A maior correlação isolada. Isso confirma clinicamente que a genética e o ambiente familiar compartilhado são os fatores de risco primários mais determinantes para um paciente cruzar a linha do sobrepeso para a obesidade clínica na nossa base.

Consumo de Alimentos Altamente Calóricos (FAVC): +0.2

Existe uma forte relação direta: pessoas que reportam consumo frequente de alta caloria têm muito mais probabilidade de pertencer ao grupo das classes de Obesidade.

Consumo entre Refeições (CAEC): +0.23

O hábito de "beliscar" comida entre as refeições também se mostrou um preditor forte.

Idade (Age): +0.21

A obesidade tende a aumentar conforme a idade avança no conjunto de dados, mostrando que o metabolismo ou as mudanças de rotina com a idade desempenham um papel relevante.

Monitoramento de Calorias (SCC): -0.19 e Atividade Física (FAF): -0.15

Estas são as correlações negativas mais fortes. Isso significa que quanto mais o paciente monitora suas calorias e quanto maior a sua frequência de atividades físicas, menor a chance dele pertencer aos grupos de obesidade severa.

APRENDIZADO DE MÁQUINA - MACHINE LEARNING


Como o objetivo é desenvolver uma aplicação que possa ajudar a equipe médica a identificar tendência de obesidade de acordo com dados comportamentais, desenvolvemos um modelo de aprendizado de máquina baseado apenas nos dados comportamentais, desconsiderando peso e altura, conseguindo uma acurácia de 80,34%.

🔗 Acurácia do Modelo Pura e Comportamental: 80.38%

📄 Relatório de Classificação Detalhado:

	precision	recall	f1-score	support
Insufficient_Weight	0.83	0.91	0.87	54
Normal_Weight	0.60	0.66	0.63	58
Obesity_Type_I	0.77	0.77	0.77	70
Obesity_Type_II	0.88	0.85	0.86	60
Obesity_Type_III	0.98	0.98	0.98	65
Overweight_Level_I	0.83	0.74	0.78	58
Overweight_Level_II	0.73	0.71	0.72	58
accuracy			0.80	423
macro avg	0.80	0.80	0.80	423
weighted avg	0.81	0.80	0.80	423

Matriz de Confusão - Somente Comportamento (Acurácia: 80.38%)



Acurácia de 80.38%

Conseguir prever a faixa de peso de uma pessoa com 80% de precisão baseando-se apenas em um questionário de rotina e genética mostra que há bons dados comportamentais desta base.

Precisão para Obesidade

Mesmo sem saber o peso, o modelo acerta quem está em Obesity_Type_III com **98% de precisão**. Isso indica que os hábitos de quem está nesse estágio (ou o perfil genético/idade) são padrões muito distintos e fáceis de identificar.

A Fronteira do Peso Normal

O *f1-score* para Normal_Weight ficou em **0.63**. O modelo confunde muito pessoas de peso normal com pessoas com baixo peso (Insufficient_Weight) ou sobrepeso leve (Overweight_Level_I). Isso acontece porque, comportamentalmente falando, uma pessoa com peso normal e uma com sobrepeso leve podem ter rotinas de alimentação e exercícios virtualmente idênticas no dia a dia.

Aplicativo

O aplicativo para auxiliar a equipe médica pode ser acessado através do link:

CONCLUSÃO

A obesidade é uma condição clínica tão grave, que é considerada um problema de saúde pública.

O texto abaixo foi extraído do site oficial do Ministério da Saúde:

“O Ministério da Saúde reconhece a obesidade como um problema de saúde pública e orienta que, diante do atual quadro epidemiológico do país, sejam prioritárias as ações de promoção da alimentação adequada e saudável, de prevenção da obesidade e intervenções para a construção de ambientes alimentares saudáveis.

Tal qual uma orquestra, o corpo humano funciona como um sistema em que cada parte exerce uma função em prol do todo. Isso inclui características como quantidade de água no corpo, de massa magra, o peso e o percentual de gordura. Quando dentro de um parâmetro adequado, esse percentual é positivo para a saúde. Mas quando esse limite é extrapolado, é hora de ligar o sinal de alerta.

Do ponto de vista conceitual, tanto o sobrepeso quanto a obesidade se referem ao acúmulo excessivo de gordura corporal, um guarda-chuva que inclui todos os outros conceitos. A obesidade é fator de risco para outras enfermidades, como: doenças cardiovasculares, diabetes, hipertensão e alguns tipos de câncer. Isso sem falar da maneira como o problema é visto pela sociedade, podendo levar a estereótipos e discriminação. E é justamente nesse ponto que fica evidente como aspectos sociais e psicológicos do indivíduo podem ser afetados, para além da questão física.

A prevalência de obesidade tem aumentado de maneira epidêmica entre crianças e adolescentes nas últimas quatro décadas e, atualmente, representa um grande problema de saúde pública no mundo. No Brasil, o excesso de peso (que compreende o sobrepeso e a obesidade) também tem aumentado em todas as faixas etárias.

De acordo com a Pesquisa Nacional de Saúde (PNS, 2020), atualmente mais da metade dos adultos apresenta excesso de peso (60,3%, o que representa 96 milhões de pessoas), com prevalência maior no público feminino (62,6%) do que no masculino (57,5%). Um em cada cinco adolescentes com idades entre 15 e 17 anos estava com excesso de peso (19,4%) e 6,7% estavam com obesidade. Em 2021, dados do Relatório público do

Sistema Nacional de Vigilância Alimentar e Nutricional mostram que, das crianças acompanhadas na Atenção Primária à Saúde, 15,8% dos menores de 5 anos e 33,9% das crianças entre 5 e 9 anos tinham excesso de peso, e dessas, 7,6% e 17,8%, respectivamente, apresentavam obesidade segundo o Índice de Massa Corporal (IMC) para idade. Quanto aos adolescentes acompanhados na APS em 2021, 32,7% e 13,0% apresentavam excesso de peso e obesidade, respectivamente.

A obesidade em crianças e adolescentes é um problema grave, que ocasiona repercussões deletérias importantes em crianças, adolescentes, jovens e adultos, além de sobrecarregar o SUS com altos custos relacionados ao tratamento do agravo e de suas complicações.

No caso da obesidade infantil, muitas crianças estão crescendo em ambientes obesogênicos. Ou seja, aqueles que promovem ou favorecem comportamentos sedentários e escolhas alimentares não saudáveis com presença de alimentos ultraprocessados, ricos em gorduras, sódio, aditivos químicos e pobres em nutrientes.”

Estes dados apresentados pelo Ministério da Saúde do Brasil corroboram com os insights obtidos através da nossa pesquisa, ainda que a base de dados aparentemente não seja do Brasil. Isso mostra que o problema de obesidade é mundial e precisa ser combatido com muita informação e incentivo a prática de hábitos mais saudáveis. Países mais desenvolvidos, como os Países Baixos (Holanda), incentivam o uso de bicicleta como transporte público e tem projeto de substituição da base da alimentação de sua população para 70% de origem vegetal até 2030.